

Projektbericht

Sentimentanalyse von Produktrezensionen

Studiengang

”Angewandte Künstliche Intelligenz”

Natural Language Processing **DLBAIPNLP01_D**

Dawid Jedlinski

Matrikelnummer: IU14113900

dawid.jedlinski@iu-study.org

Tutor: Maja Popovic

Abgabedatum: dd.mm.yyyy

Inhaltsverzeichnis

I. Abbildungsverzeichnis	III
II. Tabellenverzeichnis	IV
III. Abbreviations	V
1. Einleitung	1
1.1. Problemstellung	1
1.2. Zielsetzung	1
1.3. Vorgehensweise	1
2. Explorative Datenanalyse	2
2.1. Datensatz	2
2.2. Gewählte Kategorien	2
2.3. Verteilung der Bewertungen	2
3. Datenvorverarbeitung	3
3.1. Data Cleaning	3
3.2. Textaufbereitung	3
3.3. Numerische Repräsentation	3
3.4. Trennung von Eingabe- und Ausgabedaten	3
4. Modell und Methodik	4
4.1. Logistische Regression	4
4.2. Multinomial Naive Bayes	4
4.3. Trainingsprozess	5
5. Evaluation und Ergebnisse	6
5.1. Evaluationsmetriken	6
5.2. Gesamtergebnisse	6
5.3. Ergebnisse von zwei Algorithmen (optional)	6
6. Schluss	7

I. Abbildungsverzeichnis

II. Tabellenverzeichnis

III. Abbreviations

EDA	Explorative Datenanalyse
GMM	Gaussian Mixture Model
HR	Human Resources
LLE	Locally Linear Embedding
MDS	Multidimensional Scaling
MH	Mental Health (Mentale Gesundheit)
ML	Machine Learning
NLP	Natural Language Processing
OSMI	Open Sourcing Mental Illness
PCA	Principal Component Analysis

1. Einleitung

Online-Produktrezensionen sind eine zentrale Informationsquelle im E-Commerce und beeinflussen maßgeblich Kaufentscheidungen. Sie enthalten wertvolle Rückmeldungen zu Produktqualität und Nutzererfahrungen und bilden eine umfangreiche Datenbasis für Unternehmen. Um diese Informationen systematisch auszuwerten, wird oft eine Sentimentanalyse verwendet. Dieses Verfahren extrahiert Meinungen und Emotionen aus Texten und klassifiziert sie hinsichtlich ihrer Polarität. Die Bewertung erfolgt häufig über Klassen oder numerische Skalen [4].

1.1. Problemstellung

Online-Rezensionen liegen in großer Anzahl vor und sind aufgrund ihrer Sprachvielfalt und subjektiven Ausdrucksweise nur schwer manuell auswertbar. Eine systematische Analyse ist zeitaufwendig und nicht sinnvoll skalierbar. Automatische Sentimentanalyse-Systeme müssen mehrdeutige Formulierungen, implizite Bewertungen und unterschiedliche sprachliche Ausdrücke korrekt verarbeiten. Dabei sind eine eindeutige Repräsentation von Meinungen, die Zusammenführung semantisch ähnlicher Aussagen sowie die Ableitung nicht explizit genannter Informationen erforderlich [3]. Zudem sind fein abgestufte Bewertungen, wie Sternebewertungen, oft aussagekräftiger als binäre Klassifikationen [6].

1.2. Zielsetzung

Ziel dieser Arbeit ist die Entwicklung eines automatischen Textklassifikationssystems zur Sentimentanalyse von Online-Produktrezensionen. Das System soll in der Lage sein, Textbewertungen einer numerischen Skala von 1 bis 5 Sternen zuzuordnen und damit eine Mehrklassen-Klassifikation durchzuführen. Der Fokus liegt auf der Nutzung maschineller Lernverfahren, da diese im Vergleich zu regelbasierten Ansätzen besser mit sprachlicher Vielfalt, Tippfehlern und unbekannten Ausdrücken umgehen können und übergeordnete Sinnzusammenhänge erkennen [6]. Zu diesem Zweck werden zwei etablierte Klassifikationsmodelle eingesetzt: logistische Regression und Multinomial Naive Bayes. Ziel ist es, die Leistungsfähigkeit dieser beiden Ansätze zu vergleichen und ihre Eignung für die Vorhersage fein abgestufter Bewertungen zu bewerten.

1.3. Vorgehensweise

Zu Beginn der Arbeit erfolgt eine explorative Datenanalyse, um einen Überblick über den Datensatz, dessen Struktur sowie zentrale Eigenschaften zu gewinnen. Darauf aufbauend wird die Datenvorverarbeitung beschrieben, die unter anderem Schritte zur Textbereinigung und Merkmalsextraktion umfasst. Anschließend werden die eingesetzten Klassifikationsverfahren vorgestellt und methodisch eingeordnet. Im Rahmen des Modelltrainings werden eine logistische Regression sowie ein Multinomial-Naive-Bayes-Klassifikator implementiert und trainiert. Die Leistungsfähigkeit der Modelle wird mithilfe geeigneter Evaluationsmetriken bewertet und miteinander verglichen. Abschließend werden die Ergebnisse diskutiert und im Hinblick auf die Stärken und Schwächen der jeweiligen Ansätze analysiert.

2. Explorative Datenanalyse

hier wird der Datensatz genauer analysiert

2.1. Datensatz

[2] Der Amazon Reviews'23-Datensatz ist eine groß angelegte Sammlung von Amazon-Produktrezensionen, die im Jahr 2023 vom McAuley Lab veröffentlicht wurde. Er dient als umfassende Ressource für Forschung in den Bereichen Textanalyse, Empfehlungs- und Retrieval-Systeme sowie maschinelles Lernen.

Der Datensatz umfasst über 571 Millionen Nutzerrezensionen, die zwischen Mai 1996 und September 2023 gesammelt wurden, und enthält Informationen zu mehr als 48 Millionen Produkten aus über 30 Produktkategorien sowie zu mehr als 54 Millionen Nutzer-IDs. Damit ist die Version von 2023 deutlich größer und umfassender als frühere Amazon-Review-Datensätze.

Der Datensatz besteht aus verschiedenen miteinander verknüpften Komponenten: - User Reviews: Enthält die Bewertungen von Nutzerinnen und Nutzern, einschließlich Sternbewertungen (rating), Titel, Textkörper (text), hilfreiche Stimmen, Produkt-IDs (asin, parent_asin), verifizierte Käufe und Zeitstempel. - Item Metadata: Produktinformationen wie Beschreibungen, Preisangaben und weitere Attribute, die den Artikeln zugeordnet sind. - Links: Beziehungen zwischen Usern und Produkten

2.2. Gewählte Kategorien

- Kategorien: allbeauty, handmadeProducts und healthAndPersonalCare, da sie von der Größe ähnlich sind (knapp 300MB) und semantisch unterschiedlich. Anzahl Rezensionen: AllBeauty - 701.528 HandmadeProducts - 664.162 HealthAndPersonalHealth - 494.121 - es gibt 10 verschiedene Spalten, hauptsächlich type object, aber auch DateTime und 2 int64 für Rating und HelpfulVote, und bool bei verified_purchase - zum Glück gibts bei keiner Spalte fehlende Werte

2.3. Verteilung der Bewertungen

- AllBeauty mean bei 3.96 - HandmadeProducts mean bei 4.49 - HealthAndPersonalHealth mean bei 3.99 also sehr positiver Datensatz, jedoch nicht stark einseitig - std ist bei allen auch nicht groß liegt bei 1.4 ungefähr - die meisten Ratings sind 5, also später die Klassen ausgleichen, und Datenmenge sowieso reduzieren - wichtig zu erwähnen ist, dass bei handmade bei 5% reviews der Einkauf nicht verifiziert wurde, bei AllBeauty und Healthcare sind es sogar 10% - die Textlänge ist bis auf wenige Ausreißer bei AllBeauty und HealthCare gleich, Handmade hat etwas kürze - Bei Länge von Bewertungen, sieht man das min = 0 ist. D.h. obwohl es keine missing-values gab, gibt es trotzdem Bewertungen ohne Text, die man bei der Vorverarbeitung entfernen muss
BILDER VIELLEICHT IMPORTIEREN VON EDA?

3. Datenvorverarbeitung

- irgendwas über Preprocessing _____

3.1. Data Cleaning

- Datenmenge reduzieren und die Verteilung von Rating ausgleichen - alle reviews löschen die nicht verifizierten Kauf haben - alle mit Textlänge ≤ 10 löschen - alle spalten löschen die unnötig sind (es bleiben nur: rating, title, text)

3.2. Textaufbereitung

- Zusammenführung von Titel und Text - lowercasing - Tokenisierung - Entfernen von Stoppwörtern - Umgang mit Sonderzeichen (Punctuation) - Entfernung von Emojis - Lemmatization (langsamer, aber genauer als Stemming und das ist hier wichtiger) - lemmatisierung ist bei default nur auf Nomen eingestellt, deswegen müssen wir zuerst ein POS-Tagging machen um jedes Wort mit der Wortart zu taggen. Als erstens wird pos_tag einen Tag zuweisen, danach muss man den - abhängig von der Ausgabe - die richtige Kategorie an lemmatizer übergeben

3.3. Numerische Repräsentation

- es wird für jedes df eine spalte category erstellt mit value (allbeauty, handmade oder healthcare) um es dann nachdem zusammenführen besser zu unterscheiden. Dies hilft bei einer gleichmäßigen Aufteilung in Train und Test. - danach alle 3 DF zusammenführen - hier wird es gesplittet. Train 0.8, Test 0.2, gleichmäßig nach category mithilfe von stratify-argument - Verwendung von TF-IDF da viele Wörter redundant (product, use, one, etc.), hebt wichtige wörter hervor (excellent, terrible, perfect) BoW zählt nur Wörter und beachtet keine Relevanz - n_gram auf 1,5 damit negationen erkannt werden, minDF auf 5 (Wort muss mind. in 5 Rezensionen vorkommen sonst unwichtig), maxDF auf 0.95 (wenn ein Wort mehr als in 95% der Rezensionen vorkommt dann unnötig) - traindaten fitten und transformieren, testdaten nur transformieren - alle daten und tfidf als datei speichern

3.4. Trennung von Eingabe- und Ausgabedaten

- Definition der Zielvariable (numerische Bewertung) EINGABE (Features, X): Text = Titel + Beschreibung
AUSGABE (Target, y): Rating = 1, 2, 3, 4, 5 Sterne das vielleicht erst beim Modell und als Funktion! (text als eingabe und dann die gleiche Reihenfolge wie bei Preprocessing)

4. Modell und Methodik

- Problemformulierung als Klassifikationsaufgabe - Supervised Learning - Mehrklassen-Klassifikation (5 Klassen)
- [1] A classification model can be either generative or discriminative. - generative: based on probability distribution
- discriminative: learns borders between classes

4.1. Logistische Regression

- [1] discriminative - [1] kategorien selbst bestimmen - Beschreibung des gewählten Klassifikators - Begründung der Eignung für Textklassifikation [1] "Logistic Regression ist discriminative.

Merkmale müssen nicht kategorial sein. Man kann BoW nutzen oder was anderes. Hier wird jedes Feature mit einem Gewicht multipliziert und anschließend ein Bias addiert. Die Klassenwahrscheinlichkeit erhält man durch [Normalisierung mit Softmax (Aktivierungsfunktion für multinomiale LR)]. Dies ergibt einen K-dimensionalen Vektor (Wahrscheinlichkeitsverteilung für jede Klasse K) [3, Chapter 4] Keine starken Annahmen wie bei Naive Bayes. einfach, keine Unabhängigkeitsannahmen, aber nicht so schnell"

4.2. Multinomial Naive Bayes

- [1] generative - [1] rechnet mit wahrscheinlichkeiten - Beschreibung des gewählten Klassifikators - Begründung der Eignung für Textklassifikation [1] "Naive Bayes ist generative. Die Annahmen sind: - Wortfolge ist egal
- Merkmale (also die Wörter) sind unabhängig voneinander wenn die Klasse bekannt ist Das Auftreten von „good“ ist unabhängig vom Auftreten von „very“, wenn wir wissen, dass der Text positiv ist. In Wirklichkeit ist es nicht immer der Fall, deswegen NAIVE

Daten müssen kategorial sein, also diskret. Meistens ist die Repräsentation ein BoW-Vektor, also es sind Zählwerte von Wörtern

einfach, schnell, aber unrealistische Unabhängigkeitsannahmen"

[3, Chapter B] NAIVE BAYES - Laplace-Glättung (Add-one smoothing): um zu verhindern, dass die Wahrscheinlichkeit für ein Wort, das nicht im Trainingsset vorkam, Null wird, was die gesamte Berechnung zerstören würde - Binarisierung: Bei der Sentimentanalyse ist es oft wichtiger, OB ein Wort vorkommt, als wie oft. Hierbei werden Wortzählungen auf 1 begrenzt, was die Performance oft verbessert

Sentiment-Lexika: Wenn wenig Trainingsdaten vorhanden sind, können vordefinierte Listen positiver und negativer Wörter (z. B. MPQA) als Merkmale genutzt werden.

VERGLEICH - Both methods are simple; Naive Bayes is the simplest one. - Both methods are interpretable: you can look at the features which influenced the predictions most (in Naive Bayes - usually words, in logistic regression - whatever you defined). - Naive Bayes is very fast to train - it requires only one pass through the training data to evaluate the counts. For logistic regression, this is not the case: you have to go over the data many times until the gradient ascent converges. - Naive Bayes is too "naive it assumed that features (words) are conditionally independent given class. Logistic regression does not make this assumption - we can hope it is better. - Both methods use manually defined feature representation (in Naive Bayes, BOW is the standard choice, but you still choose this yourself). While manually defined features are good for interpretability, they may be not so good for performance - you are likely to miss something which can be useful for the task.

4.3. Trainingsprozess

- Training auf dem Trainingsdatensatz - Begründung des Vorgehens - beim Training der beiden Modelle wurde zusätzlich eine Pipeline erstellt um das beste NGram für Vektorisierung zu finden. Dabei wurde der F1-Score analysiert - es wurden (1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (1, 6) untersucht - dabei wurde auch die Trainingszeit gemessen - Ergebnisse - größter Sprung bei beiden von (1,2) auf (1,3). F1Score zwischen (1,5) und (1,6) ist nicht groß, aber die Trainingsdauer ist fast 1.5x länger. Daher wird (1,5) gewählt - die beiden Modelle sind für eigene Benutzereingabe zu verwenden unter ...

5. Evaluation und Ergebnisse

- irgendwas... - accuracy bei beiden ungefähr 55%, scheint wenig zu sein, aber es ist normal bei multiclass, bei 5 klassen hatten die auch ähnliche werte (60%), bei binär wäre 80-90%. Grund: the more classes, the less patterns. Außerdem ist es schwierig eine subjektive meinung zuordnen, da semantisch gesehen nicht jedes review das passende rating zu seinem text hat _____

5.1. Evaluationsmetriken

- Accuracy, precision, ... - Confusion Matrix - Begründung der Metrikauswahl (Sentimentanalyse ist ein typisches Klassifizierungsproblem)

5.2. Gesamtergebnisse

- Accuracy auf dem Testsatz - Darstellung und Interpretation der Confusion Matrix

5.3. Ergebnisse von zwei Algorithmen (optional)

- Vergleich der Modellleistung zwischen Algorithmen (z.B. Naive Bayes und NN) - Kurze Analyse der Unterschiede

6. Schluss

Problem mit negationen - Ironie/Sarkasmus - Polysemie, mehrdeutige wörter - "mad angry, "mad fun positive Bedeutung hier gehts um subjektive bewertung, manchmal ordnen die leute ihrem text nicht das richtige rating zu, z.b. 4 statt 5 oder 3 statt 2, daher auch solche werte der Modelle

Multipolarität - Teil positiv, Teil negativ

[4]HERAUSFORDERUNGEN - Kontextabhängigkeit: Ein Wort kann je nach Produkt positiv oder negativ sein (z. B. ein „dünner“ Laptop ist positiv, „dünne“ Wände im Hotel sind negativ) - Sprachliche Nuancen: Sarkasmus, Ironie, Redewendungen und grammatikalische Komplexität sind für KI-Tools schwer zu interpretieren. - Subjektivität: Was eine Person als positiv empfindet, kann für eine andere neutral wirken.