

Projektbericht

Sentimentanalyse von Produktrezensionen

Studiengang

”Angewandte Künstliche Intelligenz”

Natural Language Processing

DLBAIPNLP01_D

Dawid Jedlinski

Matrikelnummer: IU14113900

dawid.jedlinski@iu-study.org

Tutor: Maja Popovic

Abgabedatum: dd.mm.yyyy

Inhaltsverzeichnis

I. Abbildungsverzeichnis	III
II. Tabellenverzeichnis	IV
III. Abbreviations	V
1. Einleitung	1
1.1. Problemstellung	1
1.2. Zielsetzung	1
1.3. Vorgehensweise	1
2. Explorative Datenanalyse	2
2.1. Datensatz	2
2.2. Gewählte Kategorien	2
2.3. Verteilung der Bewertungen	3
3. Datenvorverarbeitung	4
3.1. Datenbereinigung	4
3.2. Textaufbereitung	4
3.3. Numerische Repräsentation	5
3.4. Trennung von Eingabe- und Ausgabedaten	6
4. Modell und Methodik	7
4.1. Logistische Regression	7
4.2. Multinomial Naive Bayes	7
4.3. Trainingsprozess	8
5. Evaluation und Ergebnisse	9
5.1. Evaluationsmetriken	9
5.2. Gesamtergebnisse	9
5.3. Ergebnisse von zwei Algorithmen (optional)	9
6. Schluss	10

I. Abbildungsverzeichnis

1.	Rating-Verteilung von AllBeauty	3
2.	Verifizierte Käufe von HandmadeProducts	3
3.	Ergebnisse der N-Gramme bei Logistischer Regression	5
4.	Vorverarbeitungsprozess. Quelle: eigene Darstellung	6

II. Tabellenverzeichnis

III. Abbreviations

EDA	Explorative Datenanalyse
GMM	Gaussian Mixture Model
HR	Human Resources
LLE	Locally Linear Embedding
MDS	Multidimensional Scaling
MH	Mental Health (Mentale Gesundheit)
ML	Machine Learning
NLP	Natural Language Processing
OSMI	Open Sourcing Mental Illness
PCA	Principal Component Analysis

1. Einleitung

Online-Produktrezensionen sind eine zentrale Informationsquelle im E-Commerce und beeinflussen maßgeblich Kaufentscheidungen. Sie enthalten wertvolle Rückmeldungen zu Produktqualität und Nutzererfahrungen und bilden eine umfangreiche Datenbasis für Unternehmen. Um diese Informationen systematisch auszuwerten, wird oft eine Sentimentanalyse verwendet. Dieses Verfahren extrahiert Meinungen und Emotionen aus Texten und klassifiziert sie hinsichtlich ihrer Polarität. Die Bewertung erfolgt häufig über Klassen oder numerische Skalen [4].

1.1. Problemstellung

Online-Rezensionen liegen in großer Anzahl vor und sind aufgrund ihrer Sprachvielfalt und subjektiven Ausdrucksweise nur schwer manuell auswertbar. Eine systematische Analyse ist zeitaufwendig und nicht sinnvoll skalierbar. Automatische Sentimentanalyse-Systeme müssen mehrdeutige Formulierungen, implizite Bewertungen und unterschiedliche sprachliche Ausdrücke korrekt verarbeiten. Dabei sind eine eindeutige Repräsentation von Meinungen, die Zusammenführung semantisch ähnlicher Aussagen sowie die Ableitung nicht explizit genannter Informationen erforderlich [3]. Zudem sind fein abgestufte Bewertungen, wie Sternebewertungen, oft aussagekräftiger als binäre Klassifikationen [6].

1.2. Zielsetzung

Ziel dieser Arbeit ist die Entwicklung eines automatischen Textklassifikationssystems zur Sentimentanalyse von Online-Produktrezensionen. Das System soll in der Lage sein, Textbewertungen einer numerischen Skala von 1 bis 5 Sternen zuzuordnen und damit eine Mehrklassen-Klassifikation durchzuführen. Der Fokus liegt auf der Nutzung maschineller Lernverfahren, da diese im Vergleich zu regelbasierten Ansätzen besser mit sprachlicher Vielfalt, Tippfehlern und unbekannten Ausdrücken umgehen können und übergeordnete Sinnzusammenhänge erkennen [6]. Zu diesem Zweck werden zwei etablierte Klassifikationsmodelle eingesetzt: logistische Regression und Multinomial Naive Bayes. Ziel ist es, die Leistungsfähigkeit dieser beiden Ansätze zu vergleichen und ihre Eignung für die Vorhersage fein abgestufter Bewertungen zu bewerten.

1.3. Vorgehensweise

Zu Beginn der Arbeit erfolgt eine explorative Datenanalyse, um einen Überblick über den Datensatz, dessen Struktur sowie zentrale Eigenschaften zu gewinnen. Darauf aufbauend wird die Datenvorverarbeitung beschrieben, die unter anderem Schritte zur Textbereinigung und Merkmalsextraktion umfasst. Anschließend werden die eingesetzten Klassifikationsverfahren vorgestellt und methodisch eingeordnet. Im Rahmen des Modelltrainings werden eine logistische Regression sowie ein Multinomial-Naive-Bayes-Klassifikator implementiert und trainiert. Die Leistungsfähigkeit der Modelle wird mithilfe geeigneter Evaluationsmetriken bewertet und miteinander verglichen. Abschließend werden die Ergebnisse diskutiert und im Hinblick auf die Stärken und Schwächen der jeweiligen Ansätze analysiert.

2. Explorative Datenanalyse

In diesem Kapitel wird der verwendete Datensatz im Rahmen einer explorativen Datenanalyse (EDA) untersucht. Ziel ist es, ein grundlegendes Verständnis der Datenstruktur, zentraler Eigenschaften sowie potenzieller Auffälligkeiten zu gewinnen. Hierzu zählen insbesondere statistische Kennzahlen, Verteilungen und relevante Besonderheiten des Datensatzes.

2.1. Datensatz

Der Amazon Reviews'23-Datensatz ist eine umfangreiche Sammlung von Produktrezensionen, die 2023 vom McAuley Lab veröffentlicht wurde. Er wird häufig in der Forschung zu Textanalyse, Empfehlungssystemen und maschinellem Lernen eingesetzt. Insgesamt umfasst der Datensatz über 571 Millionen Nutzerrezensionen aus dem Zeitraum von Mai 1996 bis September 2023. Die Bewertungen beziehen sich auf mehr als 48 Millionen Produkte aus über 30 Kategorien und stammen von mehr als 54 Millionen Nutzerinnen und Nutzern. Damit stellt die Version von 2023 die bislang größte und umfassendste Ausprägung der Amazon-Review-Datensätze dar und erlaubt Analysen in bisher nicht erreichter Skalierung. [2] Der Datensatz ist modular aufgebaut und besteht aus mehreren miteinander verknüpften Komponenten, darunter *User Reviews*, *Item Metadata* und *Links*. Den Kern bilden die *User Reviews*, welche neben den vergebenen Sternebewertungen auch Titel und Textkörper der Rezensionen enthalten. Ergänzend sind Zeitstempel, Informationen zu verifizierten Käufen sowie weitere nutzer- und produktspezifische Attribute enthalten. Im Rahmen dieser Arbeit wurden ausschließlich die *User Reviews* verwendet, da der Fokus auf der Analyse der textuellen Nutzerbewertungen und ihrer sentimentbezogenen Eigenschaften liegt. Die weiteren Komponenten des Datensatzes wurden nicht berücksichtigt.

2.2. Gewählte Kategorien

Für die Analyse wurden die Kategorien AllBeauty, HandmadeProducts und HealthAndPersonalCare ausgewählt. Die Auswahl erfolgte gezielt, um sowohl eine vergleichbare Datengröße von jeweils knapp 300 MB als auch inhaltliche Vielfalt sicherzustellen. Die Kategorien unterscheiden sich deutlich hinsichtlich der Produkttypen und der in den Rezensionen verwendeten Sprache. Die Kategorie AllBeauty umfasst 701.528 Rezensionen, HandmadeProducts 664.162 und HealthAndPersonalCare 494.121. Jede Kategorie enthält zehn Attribute, darunter Textfelder, Zeitstempel, numerische Bewertungen sowie Angaben zu verifizierten Käufen. Fehlende Werte treten in keiner der betrachteten Spalten auf, was die Datenvorverarbeitung vereinfacht.

Der Datensatz jeder Kategorie besteht aus zehn Spalten. Der überwiegende Teil der Attribute liegt im Datentyp object vor und umfasst unter anderem Textfelder wie den Rezensionstitel und den eigentlichen Rezensionstext. Zusätzlich sind Zeitstempel im DateTime-Format enthalten. Die numerischen Bewertungen (*rating*) sowie die Anzahl hilfreicher Stimmen (*helpful_vote*) sind als int64 gespeichert, während das Attribut *verified_purchase* als boolescher Wert vorliegt und angibt, ob es sich um einen verifizierten Kauf handelt.

Ein großer Vorteil des verwendeten Datensatzes besteht darin, dass in keiner der betrachteten Spalten fehlende Werte auftreten. Dadurch entfällt die Notwendigkeit zusätzlicher Imputationsschritte, was die Datenvorverarbeitung vereinfacht und die Konsistenz der Analyse erhöht.

2.3. Verteilung der Bewertungen

Die explorative Analyse zeigt, dass alle drei Kategorien überwiegend positiv bewertet sind. Die durchschnittlichen Bewertungen liegen bei 3,96 für AllBeauty, 4,49 für HandmadeProducts und 3,99 für HealthAndPersonalCare. Die Standardabweichung beträgt in allen Kategorien etwa 1,4 und weist auf eine moderate Streuung der Bewertungen hin. In allen Kategorien dominieren Fünf-Sterne-Bewertungen deutlich, was auf eine starke Klassenungleichverteilung hinweist. Daher sind im weiteren Verlauf Maßnahmen zur Reduktion und zum Ausgleich der Daten notwendig.




Abbildung 1.: Rating-Verteilung von AllBeauty

Der Anteil nicht verifizierter Käufe liegt bei etwa fünf Prozent in der Kategorie HandmadeProducts und bei rund zehn Prozent in den Kategorien AllBeauty und HealthAndPersonalCare. Diese Bewertungen werden gesondert betrachtet, da sie potenziell eine geringere Aussagekraft besitzen.




Abbildung 2.: Verifizierte Käufe von HandmadeProducts

Die Analyse der Textlängen zeigt ähnliche Verteilungen für AllBeauty und HealthAndPersonalCare, während die Rezensionen in HandmadeProducts im Durchschnitt kürzer sind. Zudem existieren Bewertungen ohne Textinhalt, die trotz klassischer *missing values* auftreten. Solche Einträge werden in der Datenvorverarbeitung entfernt, da sie für die textbasierte Analyse nicht geeignet sind.

3. Datenvorverarbeitung

Bevor maschinelle Lernmodelle auf Textdaten angewendet werden können, ist eine gründliche Datenvorverarbeitung notwendig. Diese umfasst mehrere Schritte: Zunächst werden irrelevante oder fehlerhafte Einträge entfernt und die Datenmenge reduziert. Anschließend erfolgt die Textaufbereitung, bei der die Rezensionstexte u.a. tokenisiert und lemmatisiert werden. Darauf aufbauend werden numerische Repräsentationen der Texte erstellt, die als Eingabe für die Modelle dienen. Abschließend wird das Format für die Eingabe- und Ausgabe definiert. Ziel dieses Kapitels ist es, die Rohdaten in eine konsistente und analysierbare Form zu bringen, um die Leistungsfähigkeit der nachfolgenden Modelle zu maximieren.

3.1. Datenbereinigung

Zunächst wurde die Gesamtmenge der Rezensionen reduziert. Hintergrund hierfür ist sowohl der hohe Rechenaufwand bei der Verarbeitung sehr großer Datensätze als auch die stark unausgeglichene Verteilung der Bewertungsstufen. Da Fünf-Sterne-Bewertungen in allen betrachteten Kategorien deutlich dominieren, wurden Maßnahmen zur Klassenbalancierung ergriffen.

Darüber hinaus wurden alle Rezensionen entfernt, die nicht als verifizierter Kauf gekennzeichnet sind. Diese Bewertungen können potenziell eine geringere Aussagekraft besitzen, da nicht sichergestellt ist, dass die bewertenden Personen das entsprechende Produkt tatsächlich erworben haben. Durch die Beschränkung auf verifizierte Käufe wird die Zuverlässigkeit der verwendeten Daten erhöht.

Ein weiterer Bereinigungsschritt betrifft die Länge der Rezensionstexte. Alle Einträge mit einer Textlänge von weniger als zehn Zeichen wurden aus dem Datensatz entfernt. Solche sehr kurzen Texte enthalten in der Regel keine ausreichenden semantischen Informationen, um eine sinnvolle Sentimentanalyse durchzuführen, und können das Modelltraining negativ beeinflussen.

Abschließend wurden alle Spalten entfernt, die für die durchgeführte Analyse nicht relevant sind. Für die weitere Verarbeitung und Modellierung wurden ausschließlich die Attribute *rating*, *title* und *text* beibehalten. Diese Auswahl stellt sicher, dass der Fokus vollständig auf den bewertungsbezogenen Informationen und dem textuellen Inhalt der Rezensionen liegt, während unnötige Metadaten ausgeschlossen werden.

3.2. Textaufbereitung

Im Rahmen der Textaufbereitung wurden mehrere Verarbeitungsschritte angewendet, um die Rezensionstexte für die anschließende Modellierung zu standardisieren und inhaltlich zu bereinigen. Zunächst wurden der Titel und der eigentliche Rezensionstext zu einem gemeinsamen Textfeld zusammengeführt, um alle verfügbaren textuellen Informationen zu nutzen. Abschließend erfolgte eine Umwandlung aller Zeichen in Kleinbuchstaben (Lowercasing).

Danach wurden die Texte tokenisiert, sodass sie in einzelne Wörter zerlegt vorlagen. Häufig vorkommende, aber inhaltlich wenig aussagekräftige Wörter (Stoppwörter) wurden entfernt. Zusätzlich wurden Sonderzeichen und Satzzeichen (Punctuation) bereinigt sowie Emojis aus den Texten entfernt, da diese in der gewählten textbasierten Repräsentation nicht weiterverarbeitet werden.

Für die Normalisierung der Wortformen wurde eine Lemmatisierung eingesetzt. Im Vergleich zum Stemming ist diese zwar rechenintensiver, liefert jedoch sprachlich präzisere Ergebnisse, was für die Qualität der Analyse als wichtiger erachtet wurde. Da der verwendete Lemmatisierer standardmäßig nur auf Nomen ausgelegt ist, wurde zuvor ein Part-of-Speech-Tagging durchgeführt. Dabei wird jedem Token zunächst eine Wortart zugewiesen. Abhängig von diesem POS-Tag wird anschließend die jeweils passende Wortart an den Lemmatisierer übergeben, sodass eine korrekte Lemmatisierung für Verben, Adjektive und Nomen gewährleistet ist.

3.3. Numerische Repräsentation

Im nächsten Schritt wurde die Datenbasis für das Modelltraining vorbereitet und in eine numerische Form überführt. Zunächst wurde für jedes der drei DataFrames eine zusätzliche Spalte *category* erstellt, die die jeweilige Kategorie (AllBeauty, HandmadeProducts oder HealthAndPersonalCare) enthält. Diese Kennzeichnung ermöglicht es, die Daten nach dem Zusammenführen eindeutig zuzuordnen und unterstützt insbesondere eine ausgewogene Aufteilung der Daten in Trainings- und Testmenge. Anschließend wurden die drei DataFrames zu einem gemeinsamen Datensatz zusammengeführt. Die Aufteilung in Trainings- und Testdaten erfolgte im Verhältnis 80% zu 20%. Um sicherzustellen, dass alle Kategorien in beiden Teilmengen gleichmäßig vertreten sind, wurde die Aufteilung mit *stratify*-Argument anhand der Kategorie-Spalte durchgeführt.

Für die numerische Repräsentation der Texte wurde das TF-IDF-Verfahren eingesetzt. Dieses Verfahren gewichtet Wörter nicht nur nach ihrer Häufigkeit, sondern berücksichtigt auch ihre Relevanz innerhalb des gesamten Korpus. Dadurch werden häufige, aber wenig aussagekräftige Begriffe wie *product*, *use* oder *one* abgeschwächt, während inhaltlich relevante Wörter wie *excellent*, *terrible* oder *perfect* stärker hervorgehoben werden. Im Gegensatz dazu würde ein Bag-of-Words-Ansatz lediglich Wortzählungen berücksichtigen, ohne deren Bedeutung für die Unterscheidung der Klassen zu bewerten.

Zur besseren Erfassung von Negationen und kurzen Wortkombinationen wurde ein N-Gram-Bereich von (1, 5) gewählt. Die Auswahl dieses Bereichs basiert auf Voruntersuchungen, in denen verschiedene Kombinationen von (1, 1) bis (1, 6) miteinander verglichen wurden. Zwar erzielte (1, 6) einen geringfügig höheren F1-Score von 0,534, jedoch bot (1, 5) mit einem F1-Score von 0,523 bei deutlich kürzerer Berechnungszeit (133,42,s gegenüber 179,45,s) das bessere Verhältnis zwischen Leistung und Effizienz. Diese Ergebnisse basieren auf Experimenten mit der logistischen Regression, wobei sich für Multinomial Naive Bayes sehr ähnliche Resultate zeigten.

	ngram_range	f1_score_macro	duration
0	(1, 1)	0.344152	11.36
1	(1, 2)	0.344090	43.98
2	(1, 3)	0.487635	59.31
3	(1, 4)	0.492500	90.59
4	(1, 5)	0.523660	133.41
5	(1, 6)	0.534081	179.45

Abbildung 3.: Ergebnisse der N-Gramme bei Logistischer Regression

Zusätzlich wurden Schwellenwerte für die Dokumentfrequenz festgelegt. Mit *minDF*=5 werden Wörter ausgeschlossen, die in weniger als fünf Rezensionen vorkommen und somit als wenig relevant gelten. Mit *maxDF*=0,95 werden Begriffe entfernt, die in mehr als 95% der Dokumente auftreten und daher kaum trennscharfe Information liefern. Der TF-IDF-Vektorisierer wurde auf den Trainingsdaten erstellt, indem er dort gefittet und transformiert wurde. Abschließend wurden sowohl die aufbereiteten Datensätze als auch die erzeugten TF-IDF-Merkmalismatrizen mithilfe von *joblib* als Dateien gespeichert, sodass sie für das nachfolgende Modelltraining und die Evaluation reproduzierbar zur Verfügung stehen.

3.4. Trennung von Eingabe- und Ausgabedaten

Die Trennung von Eingabe- und Ausgabedaten bildet die Grundlage für das anschließende Modelltraining. Als Zielvariable wird die numerische Sternebewertung definiert, die eine Klassenzugehörigkeit von eins bis fünf Sternen repräsentiert. Diese Bewertung stellt die vorherzusagende Größe dar und wird als Ausgabevariable y verwendet.

Die Eingabedaten (Features X) bestehen aus den textuellen Informationen der Rezensionen. Hierzu werden der Rezensionstitel und der zugehörige Rezensionstext zu einem gemeinsamen Textfeld zusammengeführt, um dem Modell möglichst vollständige kontextuelle Informationen bereitzustellen.

Der gesamte Vorverarbeitungsprozess ist auf dem folgenden Bild zu sehen:




Abbildung 4.: Vorverarbeitungsprozess. Quelle: eigene Darstellung

4. Modell und Methodik

Die vorliegende Aufgabenstellung wird als Klassifikationsproblem formuliert, bei dem Textdaten einer diskreten Menge von Klassen zugeordnet werden. Da den Rezensionen bereits explizite Sternebewertungen zugeordnet sind, handelt es sich um ein überwachtes Lernproblem (Supervised Learning), bei dem Modelle anhand gelabelter Trainingsdaten erlernt werden. Konkret liegt eine Mehrklassen-Klassifikationsaufgabe mit fünf Klassen vor, die den möglichen Sternebewertungen von eins bis fünf entsprechen.

Klassifikationsmodelle lassen sich grundsätzlich in generative und diskriminative Ansätze einteilen. Generative Modelle basieren auf der Modellierung der Wahrscheinlichkeitsverteilung der Daten innerhalb der einzelnen Klassen, während diskriminative Modelle direkt Entscheidungsgrenzen zwischen den Klassen erlernen [1]. Diese Unterscheidung ist insbesondere für den Vergleich der in dieser Arbeit eingesetzten Modelle von Bedeutung.

4.1. Logistische Regression

Die logistische Regression gehört zu den diskriminativen Klassifikationsverfahren, da sie nicht die zugrunde liegende Wahrscheinlichkeitsverteilung der Daten modelliert, sondern direkt Entscheidungsgrenzen zwischen den Klassen erlernt [1].

Ein wesentlicher Vorteil der logistischen Regression besteht darin, dass die verwendeten Merkmale nicht kategorial sein müssen. Dadurch eignet sich das Verfahren besonders gut für Textklassifikationsaufgaben, bei denen kontinuierliche oder hochdimensionale Merkmalsrepräsentationen wie Bag-of-Words oder TF-IDF-Vektoren zum Einsatz kommen. Jedes Merkmal wird mit einem Gewicht multipliziert und zusammen mit einem Bias-Term zu einer linearen Kombination verarbeitet. Im Fall der multinomialen logistischen Regression wird die Klassenwahrscheinlichkeit anschließend mithilfe der Softmax-Funktion normalisiert. Dadurch entsteht ein K -dimensionaler Vektor, der eine Wahrscheinlichkeitsverteilung über alle K Klassen – in diesem Fall die fünf möglichen Sternebewertungen – repräsentiert [3, Chapter 4].

Im Vergleich zu generativen Modellen wie Naive Bayes trifft die logistische Regression keine starken Annahmen über die Unabhängigkeit der Merkmale. Diese Eigenschaft macht sie robuster gegenüber komplexen Abhängigkeiten zwischen Wörtern im Text. Zwar ist die logistische Regression in der Regel rechnerisch aufwendiger als einfache probabilistische Modelle, bietet jedoch eine höhere Flexibilität und oft bessere Ergebnisse bei realistischen Textdaten, was ihre Eignung für die vorliegende Textklassifikationsaufgabe unterstreicht. [7]

4.2. Multinomial Naive Bayes

- [1] generative - [1] rechnet mit wahrscheinlichkeiten - Beschreibung des gewählten Klassifikators - Begründung der Eignung für Textklassifikation [1] "Naive Bayes ist generative. Die Annahmen sind: - Wortfolge ist egal - Merkmale (also die Wörter) sind unabhängig voneinander wenn die Klasse bekannt ist Das Auftreten von „good“ ist unabhängig vom Auftreten von „very“, wenn wir wissen, dass der Text positiv ist. In Wirklichkeit ist es nicht immer der Fall, deswegen NAIVE

Daten müssen kategorial sein, also diskret. Meistens ist die Repräsentation ein BoW-Vektor, also es sind Zählwerte von Wörtern

einfach, schnell, aber unrealistische Unabhängigkeitsannahmen"

[3, Chapter B] NAIVE BAYES - Laplace-Glättung (Add-one smoothing): um zu verhindern, dass die Wahrscheinlichkeit für ein Wort, das nicht im Trainingsset vorkam, Null wird, was die gesamte Berechnung zerstören würde - Binarisierung: Bei der Sentimentanalyse ist es oft wichtiger, OB ein Wort vorkommt, als wie oft. Hierbei werden Wortzählungen auf 1 begrenzt, was die Performance oft verbessert

Sentiment-Lexika: Wenn wenig Trainingsdaten vorhanden sind, können vordefinierte Listen positiver und negativer Wörter (z. B. MPQA) als Merkmale genutzt werden.

VERGLEICH - Both methods are simple; Naive Bayes is the simplest one. - Both methods are interpretable: you can look at the features which influenced the predictions most (in Naive Bayes - usually words, in logistic regression - whatever you defined). - Naive Bayes is very fast to train - it requires only one pass through the training data to evaluate the counts. For logistic regression, this is not the case: you have to go over the data many times until the gradient ascent converges. - Naive Bayes is too "naive" it assumed that features (words) are conditionally independent given class. Logistic regression does not make this assumption - we can hope it is better. - Both methods use manually defined feature representation (in Naive Bayes, BOW is the standard choice, but you still choose this yourself). While manually defined features are good for interpretability, they may be not so good for performance - you are likely to miss something which can be useful for the task.

4.3. Trainingsprozess

- Training auf dem Trainingsdatensatz - Begründung des Vorgehens

5. Evaluation und Ergebnisse

- irgendwas... - accuracy bei beiden ungefähr 55%, scheint wenig zu sein, aber es ist normal bei multiclass, bei 5 klassen hatten die auch ähnliche werte (60%), bei binär wäre 80-90%. Grund: the more classes, the less patterns. Außerdem ist es schwierig eine subjektive meinung zuordnen, da semantisch gesehen nicht jedes review das passende rating zu seinem text hat _____

5.1. Evaluationsmetriken

- Accuracy, precision, ... - Confusion Matrix - Begründung der Metrikauswahl (Sentimentanalyse ist ein typisches Klassifizierungsproblem)

5.2. Gesamtergebnisse

- Accuracy auf dem Testsatz - Darstellung und Interpretation der Confusion Matrix

5.3. Ergebnisse von zwei Algorithmen (optional)

- Vergleich der Modellleistung zwischen Algorithmen (z.B. Naive Bayes und NN) - Kurze Analyse der Unterschiede

6. Schluss

Problem mit negationen - Ironie/Sarkasmus - Polysemie, mehrdeutige wörter - "mad angry, "mad fun positive Bedeutung hier gehts um subjektive bewertung, manchmal ordnen die leute ihrem text nicht das richtige rating zu, z.b. 4 statt 5 oder 3 statt 2, daher auch solche werte der Modelle

Multipolarität - Teil positiv, Teil negativ

[4]HERAUSFORDERUNGEN - Kontextabhängigkeit: Ein Wort kann je nach Produkt positiv oder negativ sein (z. B. ein „dünner“ Laptop ist positiv, „dünne“ Wände im Hotel sind negativ) - Sprachliche Nuancen: Sarkasmus, Ironie, Redewendungen und grammatikalische Komplexität sind für KI-Tools schwer zu interpretieren. - Subjektivität: Was eine Person als positiv empfindet, kann für eine andere neutral wirken.