



Projektbericht

Sentimentanalyse von Produktrezensionen

Studiengang

”Angewandte Künstliche Intelligenz”

Natural Language Processing

DLBAIPNLP01_D

Dawid Jedlinski

Matrikelnummer: IU14113900

dawid.jedlinski@iu-study.org

Tutor: Maja Popovic

Abgabedatum: dd.mm.yyyy

Inhaltsverzeichnis

I. Abbildungsverzeichnis	III
II. Abbreviations	IV
1. Einleitung	1
1.1. Problemstellung	1
1.2. Zielsetzung	1
1.3. Vorgehensweise	1
2. Explorative Datenanalyse	2
2.1. Datensatz	2
2.2. Gewählte Kategorien	2
2.3. Verteilung der Bewertungen	3
3. Datenvorverarbeitung	4
3.1. Datenbereinigung	4
3.2. Textaufbereitung	4
3.3. Numerische Repräsentation	5
3.4. Trennung von Eingabe- und Ausgabedaten	6
4. Modell und Methodik	7
4.1. Logistische Regression	7
4.2. Multinomial Naive Bayes	7
5. Evaluation und Ergebnisse	9
5.1. Evaluationsmetriken	9
5.2. Ergebnisse	9
6. Schluss	11

I. Abbildungsverzeichnis

1.	Rating-Verteilung von AllBeauty	3
2.	Verifizierte Käufe von HandmadeProducts	3
3.	Ergebnisse der N-Gramme bei Logistischer Regression	5
4.	Vorverarbeitungsprozess. Quelle: eigene Darstellung	6
5.	Classification Report, Logistische Regression	9
6.	Classification Report, Naive Bayes	10
7.	Konfusionsmatrix der beiden Algorithmen	10

II. Abbreviations

EDA	Explorative Datenanalyse
GMM	Gaussian Mixture Model
HR	Human Resources
LLE	Locally Linear Embedding
MDS	Multidimensional Scaling
MH	Mental Health (Mentale Gesundheit)
ML	Machine Learning
NLP	Natural Language Processing
OSMI	Open Sourcing Mental Illness
PCA	Principal Component Analysis

1. Einleitung

Online-Produktrezensionen sind eine zentrale Informationsquelle im E-Commerce und beeinflussen maßgeblich Kaufentscheidungen. Sie enthalten wertvolle Rückmeldungen zu Produktqualität und Nutzererfahrungen und bilden eine umfangreiche Datenbasis für Unternehmen. Um diese Informationen systematisch auszuwerten, wird oft eine Sentimentanalyse verwendet. Dieses Verfahren extrahiert Meinungen und Emotionen aus Texten und klassifiziert sie hinsichtlich ihrer Polarität. Die Bewertung erfolgt häufig über Klassen oder numerische Skalen [4].

1.1. Problemstellung

Online-Rezensionen liegen in großer Anzahl vor und sind aufgrund ihrer Sprachvielfalt und subjektiven Ausdrucksweise nur schwer manuell auswertbar. Eine systematische Analyse ist zeitaufwendig und nicht sinnvoll skalierbar. Automatische Sentimentanalyse-Systeme müssen mehrdeutige Formulierungen, implizite Bewertungen und unterschiedliche sprachliche Ausdrücke korrekt verarbeiten. Dabei sind eine eindeutige Repräsentation von Meinungen, die Zusammenführung semantisch ähnlicher Aussagen sowie die Ableitung nicht explizit genannter Informationen erforderlich [3]. Zudem sind fein abgestufte Bewertungen, wie Sternebewertungen, oft aussagekräftiger als binäre Klassifikationen [6].

1.2. Zielsetzung

Ziel dieser Arbeit ist die Entwicklung eines automatischen Textklassifikationssystems zur Sentimentanalyse von Online-Produktrezensionen. Das System soll in der Lage sein, Textbewertungen einer numerischen Skala von 1 bis 5 Sternen zuzuordnen und damit eine Mehrklassen-Klassifikation durchzuführen. Der Fokus liegt auf der Nutzung maschineller Lernverfahren, da diese im Vergleich zu regelbasierten Ansätzen besser mit sprachlicher Vielfalt, Tippfehlern und unbekannten Ausdrücken umgehen können und übergeordnete Sinnzusammenhänge erkennen [6]. Zu diesem Zweck werden zwei etablierte Klassifikationsmodelle eingesetzt: logistische Regression und Multinomial Naive Bayes. Ziel ist es, die Leistungsfähigkeit dieser beiden Ansätze zu vergleichen und ihre Eignung für die Vorhersage fein abgestufter Bewertungen zu bewerten.

1.3. Vorgehensweise

Zu Beginn der Arbeit erfolgt eine explorative Datenanalyse, um einen Überblick über den Datensatz, dessen Struktur sowie zentrale Eigenschaften zu gewinnen. Darauf aufbauend wird die Datenvorverarbeitung beschrieben, die unter anderem Schritte zur Textbereinigung und Merkmalsextraktion umfasst. Anschließend werden die eingesetzten Klassifikationsverfahren vorgestellt und methodisch eingeordnet. Im Rahmen des Modelltrainings werden eine logistische Regression sowie ein Multinomial-Naive-Bayes-Klassifikator implementiert und trainiert. Die Leistungsfähigkeit der Modelle wird mithilfe geeigneter Evaluationsmetriken bewertet und miteinander verglichen. Abschließend werden die Ergebnisse diskutiert und im Hinblick auf die Stärken und Schwächen der jeweiligen Ansätze analysiert.

2. Explorative Datenanalyse

In diesem Kapitel wird der verwendete Datensatz im Rahmen einer explorativen Datenanalyse (EDA) untersucht. Ziel ist es, ein grundlegendes Verständnis der Datenstruktur, zentraler Eigenschaften sowie potenzieller Auffälligkeiten zu gewinnen. Hierzu zählen insbesondere statistische Kennzahlen, Verteilungen und relevante Besonderheiten des Datensatzes.

... siehe Jurafsky und Martin, 2023, Kapitel 3.2 ...

2.1. Datensatz

Der Amazon Reviews'23-Datensatz ist eine umfangreiche Sammlung von Produktrezensionen, die 2023 vom McAuley Lab veröffentlicht wurde. Er wird häufig in der Forschung zu Textanalyse, Empfehlungssystemen und maschinellem Lernen eingesetzt. Insgesamt umfasst der Datensatz über 571 Millionen Nutzerrezensionen aus dem Zeitraum von Mai 1996 bis September 2023. Die Bewertungen beziehen sich auf mehr als 48 Millionen Produkte aus über 30 Kategorien und stammen von mehr als 54 Millionen Nutzerinnen und Nutzern. Damit stellt die Version von 2023 die bislang größte und umfassendste Ausprägung der Amazon-Review-Datensätze dar und erlaubt Analysen in bisher nicht erreichter Skalierung. [2] Der Datensatz ist modular aufgebaut und besteht aus mehreren miteinander verknüpften Komponenten, darunter *User Reviews*, *Item Metadata* und *Links*. Den Kern bilden die *User Reviews*, welche neben den vergebenen Sternebewertungen auch Titel und Textkörper der Rezensionen enthalten. Ergänzend sind Zeitstempel, Informationen zu verifizierten Käufen sowie weitere nutzer- und produktspezifische Attribute enthalten. Im Rahmen dieser Arbeit wurden ausschließlich die *User Reviews* verwendet, da der Fokus auf der Analyse der textuellen Nutzerbewertungen und ihrer sentimentbezogenen Eigenschaften liegt. Die weiteren Komponenten des Datensatzes wurden nicht berücksichtigt.

2.2. Gewählte Kategorien

Für die Analyse wurden die Kategorien AllBeauty, HandmadeProducts und HealthAndPersonalCare ausgewählt. Die Auswahl erfolgte gezielt, um sowohl eine vergleichbare Datengröße von jeweils knapp 300 MB als auch inhaltliche Vielfalt sicherzustellen. Die Kategorien unterscheiden sich deutlich hinsichtlich der Produkttypen und der in den Rezensionen verwendeten Sprache. Die Kategorie AllBeauty umfasst 701.528 Rezensionen, HandmadeProducts 664.162 und HealthAndPersonalCare 494.121. Jede Kategorie enthält zehn Attribute, darunter Textfelder, Zeitstempel, numerische Bewertungen sowie Angaben zu verifizierten Käufen. Fehlende Werte treten in keiner der betrachteten Spalten auf, was die Datenvorverarbeitung vereinfacht.

Der Datensatz jeder Kategorie besteht aus zehn Spalten. Der überwiegende Teil der Attribute liegt im Datentyp `object` vor und umfasst unter anderem Textfelder wie den Rezensionstitel und den eigentlichen Rezensionstext. Zusätzlich sind Zeitstempel im `DateTime`-Format enthalten. Die numerischen Bewertungen (*rating*) sowie die Anzahl hilfreicher Stimmen (*helpful_vote*) sind als `int64` gespeichert, während das Attribut *verified_purchase* als boolescher Wert vorliegt und angibt, ob es sich um einen verifizierten Kauf handelt.

Ein großer Vorteil des verwendeten Datensatzes besteht darin, dass in keiner der betrachteten Spalten fehlende Werte auftreten. Dadurch entfällt die Notwendigkeit zusätzlicher Imputationsschritte, was die Datenvorverarbeitung vereinfacht und die Konsistenz der Analyse erhöht.

2.3. Verteilung der Bewertungen

Die explorative Analyse zeigt, dass alle drei Kategorien überwiegend positiv bewertet sind. Die durchschnittlichen Bewertungen liegen bei 3,96 für AllBeauty, 4,49 für HandmadeProducts und 3,99 für HealthAndPersonalCare. Die Standardabweichung beträgt in allen Kategorien etwa 1,4 und weist auf eine moderate Streuung der Bewertungen hin. In allen Kategorien dominieren Fünf-Sterne-Bewertungen deutlich, was auf eine starke Klassenungleichverteilung hinweist. Daher sind im weiteren Verlauf Maßnahmen zur Reduktion und zum Ausgleich der Daten notwendig.




Abbildung 1.: Rating-Verteilung von AllBeauty

Der Anteil nicht verifizierter Käufe liegt bei etwa fünf Prozent in der Kategorie HandmadeProducts und bei rund zehn Prozent in den Kategorien AllBeauty und HealthAndPersonalCare. Diese Bewertungen werden gesondert betrachtet, da sie potenziell eine geringere Aussagekraft besitzen.




Abbildung 2.: Verifizierte Käufe von HandmadeProducts

Die Analyse der Textlängen zeigt ähnliche Verteilungen für AllBeauty und HealthAndPersonalCare, während die Rezensionen in HandmadeProducts im Durchschnitt kürzer sind. Zudem existieren Bewertungen ohne Textinhalt, die trotz klassischer *missing values* auftreten. Solche Einträge werden in der Datenvorverarbeitung entfernt, da sie für die textbasierte Analyse nicht geeignet sind.

3. Datenvorverarbeitung

Bevor maschinelle Lernmodelle auf Textdaten angewendet werden können, ist eine gründliche Datenvorverarbeitung notwendig. Diese umfasst mehrere Schritte: Zunächst werden irrelevante oder fehlerhafte Einträge entfernt und die Datenmenge reduziert. Anschließend erfolgt die Textaufbereitung, bei der die Rezensionstexte u.a. tokenisiert und lemmatisiert werden. Darauf aufbauend werden numerische Repräsentationen der Texte erstellt, die als Eingabe für die Modelle dienen. Abschließend wird das Format für die Eingabe- und Ausgabe definiert. Ziel dieses Kapitels ist es, die Rohdaten in eine konsistente und analysierbare Form zu bringen, um die Leistungsfähigkeit der nachfolgenden Modelle zu maximieren.

3.1. Datenbereinigung

Zunächst wurde die Gesamtmenge der Rezensionen reduziert. Hintergrund hierfür ist sowohl der hohe Rechenaufwand bei der Verarbeitung sehr großer Datensätze als auch die stark unausgeglichene Verteilung der Bewertungsstufen. Da Fünf-Sterne-Bewertungen in allen betrachteten Kategorien deutlich dominieren, wurden Maßnahmen zur Klassenbalancierung ergriffen.

Darüber hinaus wurden alle Rezensionen entfernt, die nicht als verifizierter Kauf gekennzeichnet sind. Diese Bewertungen können potenziell eine geringere Aussagekraft besitzen, da nicht sichergestellt ist, dass die bewertenden Personen das entsprechende Produkt tatsächlich erworben haben. Durch die Beschränkung auf verifizierte Käufe wird die Zuverlässigkeit der verwendeten Daten erhöht.

Ein weiterer Bereinigungs-schritt betrifft die Länge der Rezensionstexte. Alle Einträge mit einer Textlänge von weniger als zehn Zeichen wurden aus dem Datensatz entfernt. Solche sehr kurzen Texte enthalten in der Regel keine ausreichenden semantischen Informationen, um eine sinnvolle Sentimentanalyse durchzuführen, und können das Modelltraining negativ beeinflussen.

Abschließend wurden alle Spalten entfernt, die für die durchgeführte Analyse nicht relevant sind. Für die weitere Verarbeitung und Modellierung wurden ausschließlich die Attribute *rating*, *title* und *text* beibehalten. Diese Auswahl stellt sicher, dass der Fokus vollständig auf den bewertungsbezogenen Informationen und dem textuellen Inhalt der Rezensionen liegt, während unnötige Metadaten ausgeschlossen werden.

3.2. Textaufbereitung

Im Rahmen der Textaufbereitung wurden mehrere Verarbeitungsschritte angewendet, um die Rezensionstexte für die anschließende Modellierung zu standardisieren und inhaltlich zu bereinigen. Zunächst wurden der Titel und der eigentliche Rezensionstext zu einem gemeinsamen Textfeld zusammengeführt, um alle verfügbaren textuellen Informationen zu nutzen. Abschließend erfolgte eine Umwandlung aller Zeichen in Kleinbuchstaben (Lowercasing).

Danach wurden die Texte tokenisiert, sodass sie in einzelne Wörter zerlegt vorlagen. Häufig vorkommende, aber inhaltlich wenig aussagekräftige Wörter (Stoppwörter) wurden entfernt. Zusätzlich wurden Sonderzeichen und Satzzeichen (Punctuation) bereinigt sowie Emojis aus den Texten entfernt, da diese in der gewählten textbasierten Repräsentation nicht weiterverarbeitet werden.

Für die Normalisierung der Wortformen wurde eine Lemmatisierung eingesetzt. Im Vergleich zum Stemming ist diese zwar rechenintensiver, liefert jedoch sprachlich präzisere Ergebnisse, was für die Qualität der Analyse als wichtiger erachtet wurde. Da der verwendete Lemmatisierer standardmäßig nur auf Nomen ausgelegt ist, wurde zuvor ein Part-of-Speech-Tagging durchgeführt. Dabei wird jedem Token zunächst eine Wortart zugewiesen. Abhängig von diesem POS-Tag wird anschließend die jeweils passende Wortart an den Lemmatisierer übergeben, sodass eine korrekte Lemmatisierung für Verben, Adjektive und Nomen gewährleistet ist.

3.3. Numerische Repräsentation

Im nächsten Schritt wurde die Datenbasis für das Modelltraining vorbereitet und in eine numerische Form überführt. Zunächst wurde für jedes der drei DataFrames eine zusätzliche Spalte *category* erstellt, die die jeweilige Kategorie (AllBeauty, HandmadeProducts oder HealthAndPersonalCare) enthält. Diese Kennzeichnung ermöglicht es, die Daten nach dem Zusammenführen eindeutig zuzuordnen und unterstützt insbesondere eine ausgewogene Aufteilung der Daten in Trainings- und Testmenge. Anschließend wurden die drei DataFrames zu einem gemeinsamen Datensatz zusammengeführt. Die Aufteilung in Trainings- und Testdaten erfolgte im Verhältnis 80% zu 20%. Um sicherzustellen, dass alle Kategorien in beiden Teilmengen gleichmäßig vertreten sind, wurde die Aufteilung mit *stratify*-Argument anhand der Kategorie-Spalte durchgeführt.

Für die numerische Repräsentation der Texte wurde das TF-IDF-Verfahren eingesetzt. Dieses Verfahren gewichtet Wörter nicht nur nach ihrer Häufigkeit, sondern berücksichtigt auch ihre Relevanz innerhalb des gesamten Korpus. Dadurch werden häufige, aber wenig aussagekräftige Begriffe wie *product*, *use* oder *one* abgeschwächt, während inhaltlich relevante Wörter wie *excellent*, *terrible* oder *perfect* stärker hervorgehoben werden. Im Gegensatz dazu würde ein Bag-of-Words-Ansatz lediglich Wortzählungen berücksichtigen, ohne deren Bedeutung für die Unterscheidung der Klassen zu bewerten.

Zur besseren Erfassung von Negationen und kurzen Wortkombinationen wurde ein N-Gram-Bereich von (1, 5) gewählt. Die Auswahl dieses Bereichs basiert auf Voruntersuchungen, in denen verschiedene Kombinationen von (1, 1) bis (1, 6) miteinander verglichen wurden. Zwar erzielte (1, 6) einen geringfügig höheren F1-Score von 0,534, jedoch bot (1, 5) mit einem F1-Score von 0,523 bei deutlich kürzerer Berechnungszeit (133,42,s gegenüber 179,45,s) das bessere Verhältnis zwischen Leistung und Effizienz. Diese Ergebnisse basieren auf Experimenten mit der logistischen Regression, wobei sich für Multinomial Naive Bayes sehr ähnliche Resultate zeigten.

	ngram_range	f1_score_macro	duration
0	(1, 1)	0.344152	11.36
1	(1, 2)	0.344090	43.98
2	(1, 3)	0.487635	59.31
3	(1, 4)	0.492500	90.59
4	(1, 5)	0.523660	133.41
5	(1, 6)	0.534081	179.45

Abbildung 3.: Ergebnisse der N-Gramme bei Logistischer Regression

Zusätzlich wurden Schwellenwerte für die Dokumentfrequenz festgelegt. Mit *minDF*=5 werden Wörter ausgeschlossen, die in weniger als fünf Rezensionen vorkommen und somit als wenig relevant gelten. Mit *maxDF*=0,95 werden Begriffe entfernt, die in mehr als 95% der Dokumente auftreten und daher kaum trennscharfe Information liefern. Der TF-IDF-Vektorisierer wurde auf den Trainingsdaten erstellt, indem er dort gefittet und transformiert wurde. Abschließend wurden sowohl die aufbereiteten Datensätze als auch die erzeugten TF-IDF-Merkmalismatrizen mithilfe von *joblib* als Dateien gespeichert, sodass sie für das nachfolgende Modelltraining und die Evaluation reproduzierbar zur Verfügung stehen.

3.4. Trennung von Eingabe- und Ausgabedaten

Die Trennung von Eingabe- und Ausgabedaten bildet die Grundlage für das anschließende Modelltraining. Als Zielvariable wird die numerische Sternebewertung definiert, die eine Klassenzugehörigkeit von eins bis fünf Sternen repräsentiert. Diese Bewertung stellt die vorherzusagende Größe dar und wird als Ausgabevariable y verwendet.

Die Eingabedaten (Features X) bestehen aus den textuellen Informationen der Rezensionen. Hierzu werden der Rezensionstitel und der zugehörige Rezensionstext zu einem gemeinsamen Textfeld zusammengeführt, um dem Modell möglichst vollständige kontextuelle Informationen bereitzustellen.

Der gesamte Vorverarbeitungsprozess ist auf dem folgenden Bild zu sehen:




Abbildung 4.: Vorverarbeitungsprozess. Quelle: eigene Darstellung

4. Modell und Methodik

Die vorliegende Aufgabenstellung wird als Klassifikationsproblem formuliert, bei dem Textdaten einer diskreten Menge von Klassen zugeordnet werden. Da den Rezensionen bereits explizite Sternbewertungen zugeordnet sind, handelt es sich um ein überwachtes Lernproblem (Supervised Learning), bei dem Modelle anhand gelabelter Trainingsdaten erlernt werden. Konkret liegt eine Mehrklassen-Klassifikationsaufgabe mit fünf Klassen vor, die den möglichen Sternbewertungen von eins bis fünf entsprechen.

Klassifikationsmodelle lassen sich grundsätzlich in generative und diskriminative Ansätze einteilen. Generative Modelle basieren auf der Modellierung der Wahrscheinlichkeitsverteilung der Daten innerhalb der einzelnen Klassen, während diskriminative Modelle direkt Entscheidungsgrenzen zwischen den Klassen erlernen [1]. Diese Unterscheidung ist insbesondere für den Vergleich der in dieser Arbeit eingesetzten Modelle von Bedeutung.

4.1. Logistische Regression

Die logistische Regression gehört zu den diskriminativen Klassifikationsverfahren, da sie nicht die zugrunde liegende Wahrscheinlichkeitsverteilung der Daten modelliert, sondern direkt Entscheidungsgrenzen zwischen den Klassen erlernt [1].

Ein wesentlicher Vorteil der logistischen Regression besteht darin, dass die verwendeten Merkmale nicht kategorial sein müssen. Dadurch eignet sich das Verfahren besonders gut für Textklassifikationsaufgaben, bei denen kontinuierliche oder hochdimensionale Merkmalsrepräsentationen wie Bag-of-Words oder TF-IDF-Vektoren zum Einsatz kommen. Jedes Merkmal wird mit einem Gewicht multipliziert und zusammen mit einem Bias-Term zu einer linearen Kombination verarbeitet. Im Fall der multinomialen logistischen Regression wird die Klassenwahrscheinlichkeit anschließend mithilfe der Softmax-Funktion normalisiert. Dadurch entsteht ein K -dimensionaler Vektor, der eine Wahrscheinlichkeitsverteilung über alle K Klassen – in diesem Fall die fünf möglichen Sternbewertungen – repräsentiert [3, Chapter 4].

Im Vergleich zu generativen Modellen wie Naive Bayes trifft die logistische Regression keine starken Annahmen über die Unabhängigkeit der Merkmale. Diese Eigenschaft macht sie robuster gegenüber komplexen Abhängigkeiten zwischen Wörtern im Text. Zwar ist die logistische Regression in der Regel rechnerisch aufwendiger als einfache probabilistische Modelle, bietet jedoch eine höhere Flexibilität und oft bessere Ergebnisse bei realistischen Textdaten, was ihre Eignung für die vorliegende Textklassifikationsaufgabe unterstreicht. [7]

4.2. Multinomial Naive Bayes

Als zweiter Klassifikator wurde Multinomial Naive Bayes gewählt, ein generativer Ansatz, der Wahrscheinlichkeiten zur Vorhersage von Klassen nutzt [1]. Der Klassifikator geht davon aus, dass die Reihenfolge der Wörter im Text keine Rolle spielt und die Merkmale unabhängig voneinander sind, sobald die Klasse bekannt ist. Dieses Prinzip bezeichnete man als „naiv“, da die Unabhängigkeitsannahme in der Realität oft nicht zutrifft. Beispielsweise behandelt der Klassifikator das Auftreten des Wortes „good“ als unabhängig vom Auftreten des Wortes „very“, sofern der Text als positiv klassifiziert wurde. Die Eingabedaten müssen kategorial sein, weshalb die Texte in der Regel als BoW- bzw. TF-IDF-Vektoren dargestellt werden [1].

Um die Probleme bei unbekannten Wörtern zu vermeiden, wurde die Laplace-Glättung verwendet, die in der Implementierung des Naive-Bayes-Klassifikators über das `alpha`-Argument gesteuert wird. Der Wert wurde auf 1 festgelegt. Durch die Glättung wurde verhindert, dass die Wahrscheinlichkeit für ein Wort, das im Trainingsset nicht vorkam, auf Null sank und somit die gesamte Berechnung zerstörte [3, Chapter B]. Zusätzlich wurde das Argument `class_prior=None` gesetzt, wodurch der Klassifikator die Klassenwahrscheinlichkeiten aus den Trainingsdaten selbst schätzte, ohne die A-priori zu kennen.

Der Naive Bayes Klassifikator zeichnet sich durch seine Einfachheit, Geschwindigkeit und Interpretierbarkeit aus [3, Chapter B]. Das Training ist besonders effizient, da lediglich eine einzige Durchsicht der Trainingsdaten notwendig war, um die Wortzählungen zu bestimmen. Demgegenüber erforderten andere Methoden, wie etwa die logistische Regression, mehrere Iterationen über die Daten. Allerdings ist der Klassifikator auch eingeschränkt, da die Annahme der bedingten Unabhängigkeit der Merkmale oft unrealistisch ist. Zudem setzt er auf manuell definierte Features (wie BoW), wodurch potenziell nützliche Informationen übersehen werden konnten [3, Chapter B].

5. Evaluation und Ergebnisse


In diesem Kapitel werden die Ergebnisse der Klassifikation präsentiert und analysiert. Dabei liegt der Fokus auf der Leistungsbewertung der Modelle anhand gängiger Evaluationsmetriken sowie auf dem Vergleich verschiedener Algorithmen.

5.1. Evaluationsmetriken

Zur Bewertung der Leistung wurden folgende Metriken verwendet: Accuracy, Precision, Recall, F1-Score und die Konfusionsmatrix. Die Auswahl dieser Metriken wurde dadurch begründet, dass Sentimentanalyse ein klassisches Klassifizierungsproblem darstellt. Accuracy bietet einen allgemeinen Überblick über die Modellgüte, während Precision, Recall und F1-Score die Leistungsfähigkeit in Bezug auf einzelne Klassen differenzierter darstellen. Die Confusion Matrix erlaubt zudem eine detaillierte Analyse der Fehlklassifikationen.

5.2. Ergebnisse

Die Modelle wurden auf einem Testsatz von 21.258 Reviews evaluiert. Dabei erzielte die logistische Regression eine Accuracy von 0,53. Der zugehörige Classification Report zeigte, dass die Precision, der Recall und der F1-Score zwischen den Klassen variierten: Die Klasse 1 erzielte eine Precision von 0,56, einen Recall von 0,67 und einen F1-Score von 0,61. Die mittleren Klassen 2 und 3 wiesen jeweils niedrigere Werte auf. Die höchste Bewertung, Klasse 5, erreichte die besten Werte mit einem F1-Score von 0,69.



```
Accuracy: 0.5296829428920877
Classification Report:
      precision    recall  f1-score   support

     1       0.56       0.67       0.61       4376
     2       0.45       0.37       0.40       4426
     3       0.45       0.40       0.43       4223
     4       0.50       0.49       0.49       4099
     5       0.65       0.73       0.69       4134

 accuracy          0.53       21258
 macro avg         0.52       0.53       0.52       21258
 weighted avg      0.52       0.53       0.52       21258
```

Abbildung 5.: Classification Report, Logistische Regression

Der Naive-Bayes-Klassifikator erzielte eine etwas niedrigere Gesamtgenauigkeit von 0,50 und zeigte dabei ein sehr ähnliches Leistungsverhalten über die Klassen hinweg wie die logistische Regression. Besonders gut wurden die Extremklassen erkannt: Klasse 1 erreichte einen F1-Score von 0,56, während Klasse 5 mit einem F1-Score von 0,66 die beste Performance aufwies. Deutlich schwächer schnitt das Modell in den mittleren Bewertungsstufen ab, wo die F1-Scores mit 0,41 (Klasse 2) bzw. 0,43 (Klasse 3) niedriger ausfielen. Dies deutet darauf hin, dass Naive Bayes - genauso wie die Logistische Regression - klare positive oder negative Emotionen zuverlässig identifizieren kann. Es hat jedoch Schwierigkeiten, feinere Abstufungen im mittleren Bewertungsbereich zu unterscheiden.

Accuracy: 0.5030				
Classification Report:				
	precision	recall	f1-score	support
1	0.55	0.58	0.56	4376
2	0.41	0.40	0.41	4426
3	0.41	0.45	0.43	4223
4	0.50	0.41	0.45	4099
5	0.65	0.68	0.66	4134
accuracy			0.50	21258
macro avg	0.50	0.50	0.50	21258
weighted avg	0.50	0.50	0.50	21258

Abbildung 6.: Classification Report, Naive Bayes

Die Accuracy-Werte erscheinen zunächst niedrig, ist jedoch für Multiclass-Aufgaben mit mehreren Klassen typisch. Vergleichbare Studien zeigten bei fünf Klassen ähnliche Werte von etwa 60%, während binäre Klassifikationen üblicherweise 80–90% erreichen [8]. Der Grund für niedrige Accuracy-Werte bei Multiclass-Aufgaben ist, dass mit zunehmender Klassenzahl weniger eindeutige Muster existieren. Zudem erschwerte die Subjektivität der Texte die Zuordnung, da semantisch nicht jedes Review zwingend dem passenden Rating entsprach [8].

Die Analyse der Konfusionsmatrix zeigte für beide Modelle ähnliche Muster. Die Hauptdiagonale war deutlich erkennbar, was darauf hinwies, dass die meisten Reviews korrekt klassifiziert wurden. Aufgrund der Subjektivität der Bewertungen traten jedoch auch häufig Verwechslungen benachbarter Klassen auf. Beispielsweise wurden Reviews mit einer Bewertung von 1 Stern gelegentlich als 2 Sterne klassifiziert, oder 5-Sterne-Reviews als 4 Sterne. Dies führte zu einer Verstärkung der Werte in den Feldern direkt neben der Hauptdiagonale.




Abbildung 7.: Konfusionsmatrix der beiden Algorithmen

Insgesamt zeigte sich, dass beide Modelle die extremen Klassen (1 und 5 Sterne) am zuverlässigsten klassifizierten, während die mittleren Klassen stärker miteinander verwechselt wurden. Dies deutet darauf hin, dass semantisch ähnliche Reviews unterschiedlich bewertet wurden, was die Klassifikation erschwerte. Die logistische Regression erzielte dabei insgesamt leicht bessere Ergebnisse als Naive Bayes, insbesondere bei den mittleren Klassen.

6. Schluss

Die durchgeführte Analyse und Evaluation der Klassifikationsmodelle zeigte, dass die Vorhersage von Sternebewertungen auf Basis von Nutzerrezensionen zahlreiche Herausforderungen mit sich brachte. Insbesondere die subjektive Natur der Bewertungen führte dazu, dass Texte nicht immer dem objektiv passenden Rating zugeordnet wurden. So traten beispielsweise Reviews mit einem überwiegend positiven Inhalt auf, denen lediglich vier Sterne statt fünf zugewiesen wurden, oder negative Texte, die mit drei statt zwei Sternen bewertet wurden. Dieses Verhalten spiegelte sich in den Modellergebnissen wider und erklärte teilweise die moderaten Accuracy-Werte der Multiclass-Klassifikation.

Ein wesentlicher Faktor, der die Sentimentanalyse erschwerte, war die sprachliche Komplexität, die eine generelle Herausforderung in der natürlichen Sprachverarbeitung (NLP) darstellt. Typische Probleme treten bei Negationen, Ironie und Sarkasmus auf, da Modelle die sentimentale Wirkung solcher sprachlichen Mittel nur schwer korrekt erfassen können. Ebenso stellen Polysemie und mehrdeutige Wörter ein grundsätzlichen Problem in NLP dar: Ein Wort wie „mad“ kann je nach Kontext sowohl negative („angry“) als auch positive („mad fun“) Bedeutungen annehmen.

Darüber hinaus erschwert die Multipolarität von Texten die Klassifikation, da einzelne Texte oft gleichzeitig positive und negative Aspekte enthalten. Auch die Kontextabhängigkeit einzelner Wörter, sprachliche Nuancen, Redewendungen und grammatikalische Komplexität gelten allgemein als große Herausforderungen für NLP-Modelle. Diese Aspekte führen dazu, dass selbst leistungsfähige Modelle Schwierigkeiten haben, die subjektive Bewertung von Texten korrekt vorherzusagen [4].

Zusammenfassend zeigte sich, dass die moderate Performance der Modelle, insbesondere der mittleren Klassen, durch eine Kombination aus subjektiver Bewertung, Mehrdeutigkeit, Kontextabhängigkeit und sprachlichen Besonderheiten bedingt war. Die logistische Regression erzielte dabei insgesamt leicht bessere Ergebnisse als Naive Bayes, insbesondere bei der Differenzierung der mittleren Klassen, konnte jedoch nicht alle oben genannten Herausforderungen vollständig kompensieren.

Die Arbeit verdeutlichte, dass für eine robuste Sentimentanalyse weiterführende Ansätze, wie Transformer-Modelle, erforderlich sein könnten, um Negationen, Ironie, Polysemie und subjektive Bewertungen besser zu erfassen. Dennoch kann selbst bei den leistungsfähigsten Modellen die Vorhersage durch die Subjektivität der Bewertungen verzerrt sein. So kann ein Text, der nach seinem Inhalt eher einer 4-Sterne-Bewertung entspricht, von der bewertenden Person fälschlicherweise mit 3 oder 5 Sternen eingestuft worden sein, wodurch auch das beste Modell die exakte Sternezahl nicht zuverlässig vorhersagen kann.

Literaturverzeichnis

Jurafsky, D., & Martin, J. H. (2023). Speech and Language Processing [Online; Zugriff am 15.01.2026].